情感分析的基础实验

李牧之

2025 年 8 月 11 日

1 Introduction

情感分析，又称为意见挖掘，旨在识别和提取文本数据中所表达的情感、观点和主观信息，将文本内容分类到积极、消极等情感类别中。广泛应用于商业、社交媒体等需要理解用户意见的领域。本文基于 python 和 IMDB 电影评论数据集，运用词袋 (BoW)、TF-IDF、深度学习、预训练模型、大型语言模型调用等方法进行基础实验，并对模型性能进行简单对比评估。

2 Dataset

2.1 数据集信息

IMDB 电影评论数据集，包含 5 万条英语原始评论，每条评论含有真实的情感倾向标签，并且被平均分为了积极与消极两部分。
数据集中前十条数据：

	review	sentiment
0	One of the other reviewers has mentioned that ...	positive
1	A wonderful little production. The...	positive
2	I thought this was a wonderful way to spend ti...	positive
3	Basically there's a family where a little boy ...	negative
4	Petter Mattei's "Love in the Time of Money" is...	positive
5	Probably my all-time favorite movie, a story o...	positive
6	I sure would like to see a resurrection of a u...	positive
7	This show was an amazing, fresh & innovative i...	negative
8	Encouraged by the positive comments about this...	negative
9	If you like original gut wrenching laughter yo...	positive

下载链接：

`https://www.kaggle.com/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews`

2.2 数据处理

2.2.1 数据清洗 Data Cleaning

对于数据集中的数据，我们仅考虑其中的词汇，因此要去除特殊符号、数字等；同时将大小写归一化。

2.2.2 停用词过滤 Stop Words Removal

停用词（Stop Words）是指在自然语言文本中出现频率很高但对文本意义贡献很小的词，将这些词语过滤掉。

2.2.3 词干提取 Stemming

将一个词语的不同形式还原成词干，通过去除前后缀来进行，将具有相同基本意义的词语归一化。

2.2.4 深度学习方法所需要的进一步数据处理

深度学习方法不需要进行停用词过滤以及词干提取。在数据清理之后，进行词汇表的创建，每一个词语赋予独特的索引值，将评论文本转换为一串整数。大约共有 92K 的单词，其中前 10K 的单词就可以覆盖文中约 95% 的单词。所以仅考虑前 10K 的单词，并将单一评论长度限制为 500 词，短于 500 词用特殊索引填充，长于 500 词则只考虑前 500 词进行截取。

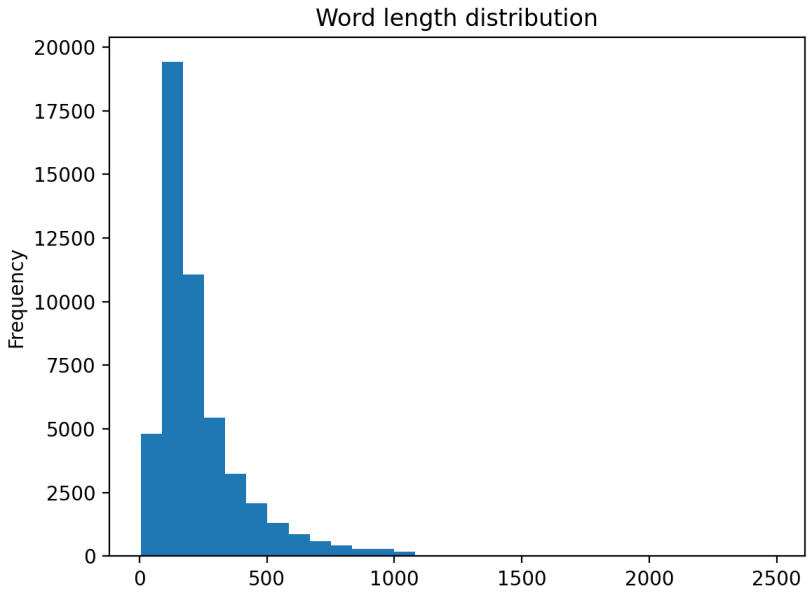

3 Methods

3.1 Bag of Words

词袋模型 (Bag of Words, 简称 BoW) 是自然语言处理中最基础、最核心的文本表示方法之一。词袋模型将文档视为无序的词汇集合，忽略语法和语序，仅统计每个词语出现的频率，将文本转化为数值向量。其基本步骤如下：1）文本预处理，进行数据清洗、停用词过滤、词干提取以及分词；2）构建词汇表，收集测试集所有文档中的所有不重复的词语，构成词汇表，单词总数称为词汇表大小 (Vocabulary Size);3）文本向量化，将每篇文档根据各单词出现的频次结合词汇表表示为词频向量 (Bag of Words Vector)，向量维度为词汇表大小，向量中的每个位置都对应着词汇表中的一个词，该位置的值为该单词出现的频次。例如，文档 1：”John likes to watch movies. Mary likes movies too.” 文档 2:”Mary

also likes to watch football games." 则构建词汇表为 ["john", "likes", "to", "watch", "movies", "mary", "too", "also", "football", "games"], 长度为 10，则文档 1 的词频向量为 [1, 2, 1, 1, 2, 1, 1, 0, 0, 0], 文档 2 的词频向量为 [0, 1, 1, 1, 0, 1, 0, 1, 1, 1]。

在词袋模型中，为了更好的提取复合短语的语义信息，可以使用 n-grams，截取连续的 n 个单词作为词汇表中的一个单词，即词频向量中的一个维度。

3.2 TF-IDF

TF-IDF 是对于词袋模型中词频向量生成方法的改进，该方法的核心思想为：一个单词的重要性与它在当前文档中的出现次数正相关，与它在所有文档中的出现次数负相关。其基本步骤如下：1）文本预处理；2）构建词汇表；3）文本向量化，将每篇文档表示为词汇向量，向量的每个位置对应词汇表中的一个词，该位置的值为该词语的 TF-IDF 值。

$$TFIDF(t,d,D) = TF(t,d) * IDF(t,D) \tag{1}$$

$$TF(t,d) = \text{单词 t 在文档 d 中的出现频次} \tag{2}$$

$$IDF(t,D) = \log(\frac{1+N}{1+DF(t)}) + 1 \tag{3}$$

给定总文档库 D，文档总数为 N，单词 t，某一文档 d，DF(t) 为包含单词 t 的文档数。根据公式(1)(2)(3)计算出单词 t 在文档 d 中的 TF-IDF 值。IDF(Inverse Document Frequency, 逆文档频率) 有多种计算方式，本文采用 sklearn 库中 TfidfVectorizer 函数的计算公式，在分子和分母上加 1 以避免某些词在所有文档中都不出现的情况，否则可能出现分母为 0 的错误。此外，sklearn 库中的 TfidfVectorizer 函数还对最终的 TF-IDF 向量进行了 L2 范数归一化，即对于每一个文档的向量，所有值的平方和为 1。

TF-IDF 模型中也可以使用 n-grams 方法以更好提取复合短语的语义信息。

3.3 Logistic Regression

逻辑回归 (Logistic Regression) 是一种用于解决二元分类问题的统计学习方法，尽管名字中含有“回归”，但它实际上是一种分类算法。其核心任务是根据输入的特征向量预测某个事件发生的概率，并根据这个概率将数据点归类到两个类别中的一个。在本文研究的情感分析任务中，输入的特征向量即为3.1,3.2中的词频向量，两个类别即为"Positive""Negative" 两种情感极性。

逻辑回归的核心工作原理如下：1）对输入的特征向量 $\mathbf{x}$ 进行加权求和，计算出一个线性得分 z，即公式(4), 其中 $\boldsymbol{\theta}$ 是模型需要通过训练来学习的权重；2）将线性得分 z 传入 Sigmoid 函数，将 z 映射成 [0,1] 之间的一个概率值，即公式(5), 若 P 大于等于 0.5，则模型预测其类别为 1，若 P 小于 0.5，则模型预测其类型为 0。

$$z = \theta_0 + \sum_{i=1}^{n} \theta_i x_i \tag{4}$$

$$P(y=1|\mathbf{x}) = \frac{1}{1+e^{-z}} \tag{5}$$

逻辑回归的训练是一个优化过程，其目标是找到一组最佳的权重，使得模型的预测概率尽可能接近真实标签。训练过程主要依赖梯度下降算法来最小化交叉熵损失 (Cross-Entropy Loss)，即公式(6), 其中 m 为样本总数,$y^{(i)}$ 为第 i 个样本的真实标签，$p(x^{(i)})$ 为第 i 个样本输出为 1 的概率。本文采用 sklearn

中的 LogisticRegression 模型，初始参数 $\boldsymbol{\theta}$ 会被赋值为不相等的近似为 0 的随机值，根据梯度下降算法更新参数，即公式(7), 其中 α 为学习率，在本文使用的模型中根据 L-BFGS 优化算法调整。多次更新参数之后损失函数的值不再显著下降，此时认为模型已经收敛。此外，sklearn 中的 LogisticRegression 模型默认使用 L2 正则化，以减缓模型的过拟合现象。

$$J(\boldsymbol{\theta}) = -\frac{1}{m}\sum_{i=1}^{m}[y^{(i)}\log(p(x^{(i)})) + (1-y^{(i)})\log(1-p(x^{(i)}))] \tag{6}$$

$$\theta_j := \theta_j - \alpha\frac{\partial}{\partial\theta_j}J(\boldsymbol{\theta}) \tag{7}$$

3.4 Linear Support Vector Machine

线性支持向量机 (Linear Support Vector Machine,LSVM) 是一种监督学习算法，主要用于解决二分类问题。其核心思想是寻找一个超平面 (hyperplane)，将不同类别的样本向量分开，并使得该超平面到两边最近的样本 (该样本被称为支持向量，Support Vectors) 的距离 (称为间隔,Margin) 最大化。训练完成后，根据输入向量与超平面的位置关系即可确认其输出。我们将标签值定义为 ±1, 记优化得到的超平面方程为(8), 则对于样本向量 $\boldsymbol{x_i}$, 预测规则为(9)。

$$\boldsymbol{w^T x} + b = 0 \tag{8}$$

$$f(\boldsymbol{x_i}) = sign(\boldsymbol{w^T x_i} + b) \tag{9}$$

LSVM 优化的基本约束条件为(10), 即对于正类样本 ($y_i = +1$), 要求 $\boldsymbol{w^T x_i} + b \geq +1$; 对于负类样本 ($y_i = -1$), 要求 $\boldsymbol{w^T x_i} + b \leq -1$, 且满足 $y_i(\boldsymbol{w^T x_i} + b) = 1$ 的数据点就是支持向量。优化目标是最大化间隔，数学上容易证明间隔大小为 $\frac{2}{\|\boldsymbol{w}\|}$, 其中 $\|\boldsymbol{w}\|$ 是向量 $\boldsymbol{w}$ 的 L2 范数，最大化 $\frac{2}{\|\boldsymbol{w}\|}$ 等价于最小化 $\|\boldsymbol{w}\|$，也等价于最小化 $\frac{1}{2}\|\boldsymbol{w}\|^2$, 因此，LSVM 的基本优化目标为(11)

$$y_i(\boldsymbol{w^T x_i} + b) \geq 1 \tag{10}$$

$$\min_{w,b}\frac{1}{2}\|\boldsymbol{w}\|^2 \quad \text{subject to} \quad y_i(\boldsymbol{w^T x_i} + b) \geq 1 \quad \forall x = 1, \cdots, n \tag{11}$$

然而，仅考虑(10)(11)无法解决一些不是完全线性可分的问题，为此，我们引入" 软间隔"(Soft Margin), 允许一些样本点被错误分类，但会对此进行惩罚。引入松弛变量 $\xi_i \geq 0$, 修改约束条件为(12), 如果 $\xi_i = 0$，表示样本点被正确分类，且位于间隔之外，如果 $0 < \xi_i < 1$，表示样本点被正确分类，但位于间隔之内，如果 $\xi_i \geq 1$，表示样本点被错误分类。同时，在优化目标中加入对松弛系数的惩罚项，即(13), 其中 C 是惩罚系数，在本文使用的 sklearn.svm.LinearSVC 模型中默认为 1.0。为了最小化总损失，ξ_i 取满足约束条件的最小值，即 $max(0, 1 - y_i(\boldsymbol{w^T x_i} + b))$, 结合(12)(13), 得到最终的目标函数，即带合页损失的软间隔 SVM(14)。

$$y_i(\boldsymbol{w^T x_i} + b) \geq 1 - \xi_i \tag{12}$$

$$\min_{w,b}\frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{n}\xi_i \quad \text{subject to} \quad y_i(\boldsymbol{w^T x_i} + b) \geq 1 - \xi_i \tag{13}$$

$$\min_{w,b}\frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{n}\max(0, 1 - y_i(\boldsymbol{w^T x_i} + b)) \tag{14}$$

对于该目标函数，本文使用模型采用序列最小优化算法 (Sequential Minimal Optimization,SMO)。

3.5 Multinomial Naive Bayes

多项式朴素贝叶斯 (Multinomial Naive Bayes, MNB) 是一种基于贝叶斯定理专门用于处理离散特征的分类算法，其核心思想" 朴素" 指的是一个强假设：假设所有特征之间是相互独立的。在情感分析任务中，这意味着文档中某个词的出现与其他词的出现是完全独立的，没有任何关联。多项式朴素贝叶斯算法的基础是贝叶斯定理，即(15), 其中 $P(C|D)$ 为后验概率 (Posterior Probability)，即在文档 D 出现的情况下属于类别 C 的概率，为预测时需要求解的目标；$P(D|C)$ 为似然度 (Likelihood)，即在类别 C 出现的情况下，文档 D 出现的概率，通过训练数据进行计算；$P(C)$ 为先验概率 (Prior Probability)，即没有任何信息的情况下一个文档属于类别 C 的概率；$P(D)$ 为证据 (Evidence)，即文档 D 出现的概率，在分类问题中可被视为常数不予考虑。最终的分类规则是寻找后验概率最大的类别 C。

$$P(C|D) = \frac{P(D|C)P(C)}{P(D)} \tag{15}$$

对于情感分析问题，文档 D 被表示成为 3.1,3.2中的词频向量，例如 $\boldsymbol{x} = (x_1, ..., x_n)$，其中 n 为词语个数,x_i 是词语 w_i 在上述方法中对应的取值 (出现次数或 TF-IDF 值)。根据所有特征相互独立的假设，我们可以将后验概率表示为(16), 为方便计算，取对数得(17)。由于最后只需比较各类别后验概率的相对大小，可以将(17)取等作为计算结果进行分类。

$$P(C|D) \propto P(C) \prod_{i=1}^{n} P(w_i|C)^{x_i} \tag{16}$$

$$\log P(C|D) \propto \log P(C) + \sum_{i=1}^{n} x_i \cdot \log P(w_i|C) \tag{17}$$

训练过程中，利用训练集的数据根据(18)(19)计算先验概率以及各词语的似然度，其中(19)使用了拉普拉斯平滑，α 为平滑参数，默认值为 1.0。预测过程，将词频向量数据带入(17)计算"Positive" 和"Negative" 对应的后验概率再进行比较，选择较大的类别作为预测结果。

$$P(C) = \frac{\text{类别 C 的文档数}}{\text{总文档数}} \tag{18}$$

$$P(w_i|C) = \frac{\text{类别 C 文档中词语 } w_i \text{ 的 } x_i \text{ 之和} + \alpha}{\text{类别 C 文档中的 } \sum_{j=1}^{n} x_j \text{ 之和} + \alpha \cdot n} \tag{19}$$

3.6 Multilayer Perception

多层感知机 (Multilayer Perception,MLP), 也被称为全连接神经网络 (Fully-connected Neutral Network), 是一种经典的深度学习模型，它由多个神经元层组成，其中每一层的神经元都与前一层所有的神经元相连接。在情感分析任务中，MLP 的核心任务是通过多个隐藏层增加非线性组合构建一个映射关系，将输入的文档映射为情感标签。

经过 2.2.4的数据处理，每条文档被处理为一个长度为 500 的整数序列，传入输入层 (InputLayer)。在嵌入层 (Embedding) 中，每一个词语被转换称为一个固定大小 (本文实验使用的大小为 32) 的嵌入向量 (Embedding Vector), 转换过程中的嵌入参数需要通过学习得到，嵌入向量能够捕捉词语之间的语义关系，相似的词语在嵌入空间中具有相似的向量表示，最后嵌入层的输出为二维数据块，经过展平层 (Flatten) 得到一个一维向量，传入全连接隐藏层 (Dense)。隐藏层中使用"ReLU" 激活函数，并设有 Dropout 层，以减缓过拟合现象，输出层采用 Sigmoid 函数，表示评论为"Positive" 标签的可能性，损失函数使用二元交叉熵损失(6), 优化器使用 Adam。

3.7 Recurrent Neutral Network

循环神经网络 (Recurrent Neutral Network,RNN) 是一种专门用于处理序列数据的神经网络，它引入了循环结构，使得模型能够利用时序信息和上下文信息。RNN 按照序列的时间步进行计算，每一个时间步 t 根据该时间步的输入 $\boldsymbol{x_t}$ 以及上一时间步计算得到的隐藏状态 $\boldsymbol{h_{t-1}}$ 计算得到该时间步的隐藏状态 $\boldsymbol{h_t}$，最终输出最后一个时间步的隐藏状态 $\boldsymbol{h_n}$ 或者所有时间步的隐藏状态序列 $[\boldsymbol{h_1}, ..., \boldsymbol{h_n}]$。本文使用的是 Keras 库中的 SimpleRNN, 根据(20)进行计算，其中 $\boldsymbol{W_{hh}}$ 为隐藏状态到隐藏状态的权重矩阵，$\boldsymbol{W_{xh}}$ 为输入到隐藏状态的权重矩阵，$\boldsymbol{b}$ 为偏置向量，$\boldsymbol{h_0}$ 默认值为 $\mathbf{0}$,tanh 是一个非线性的激活函数，可将输入压缩到 (-1,1) 的范围内。

$$\boldsymbol{h_t} = \tanh(\boldsymbol{W_{hh}}\boldsymbol{h_{t-1}} + \boldsymbol{W_{xh}}\boldsymbol{x_t} + \boldsymbol{b}) \tag{20}$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \tag{21}$$

本文在 SimpleRNN 的基础上使用双向循环层 (Bidirectional,RNN), 结合了两个独立的 RNN, 一个从序列的开头向结尾处理，另一个从序列的结尾向开头处理，并将相同时间步的隐藏状态进行拼接，返回值为两个方向最终隐藏状态的拼接。将该拼接向量传入全连接层，经 Sigmoid 函数激活后进行预测。损失函数使用二元交叉熵损失(6), 优化器使用 Adam。

3.8 LSTM

长短时记忆网络 (Long Short Term Memory,LSTM) 是一种特殊的 RNN，它通过引入" 门控机制"(Gating Machanism) 来精确控制信息的流动，从而能够有效地学习和记忆长距离的依赖关系。LSTM 的核心是一个特殊的单元结构，由细胞状态 (Cell State)，遗忘门 (Forget Gate)，输入门 (Input Gate)，输出门 (Output Gate) 构成。

一个 LSTM 单元在时间步 t 的计算如下：1) 遗忘门，决定丢弃哪些信息，它会接收当前输入 $\boldsymbol{x_t}$ 和上一时刻的隐藏状态 $\boldsymbol{h_{t-1}}$, 根据(22)计算出遗忘向量 $\boldsymbol{f_t}$, 其中 σ 是 Sigmoid 函数，$[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}]$ 是将两个向量拼接，$\boldsymbol{f_t}$ 接近 0 表示遗忘，接近 1 表示保留。

$$\boldsymbol{f_t} = \sigma(\boldsymbol{W_f} \cdot [\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_f}) \tag{22}$$

2) 输入门，决定保留哪些信息，首先根据(23)计算输入门向量 $\boldsymbol{i_t}$, 决定哪些信息需要被更新；再根据(24)计算候选细胞状态 $\tilde{\boldsymbol{C}}_{\boldsymbol{t}}$，创建一个新的候选向量用于更新细胞状态。

$$\boldsymbol{i_t} = \sigma(\boldsymbol{W_i} \cdot [\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_i}) \tag{23}$$

$$\tilde{\boldsymbol{C}}_{\boldsymbol{t}} = \tanh(\boldsymbol{W_C} \cdot [\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_C}) \tag{24}$$

3) 更新细胞状态，用遗忘向量逐元素乘旧的细胞状态丢弃旧信息，用输入门向量逐元素乘候选细胞状态添加新信息，相加得到新的细胞状态，即(25)

$$\boldsymbol{C_t} = \boldsymbol{f_t} \odot \boldsymbol{C_{t-1}} + \boldsymbol{i_t} \odot \tilde{\boldsymbol{C}}_{\boldsymbol{t}} \tag{25}$$

4) 输出门，决定最终输出什么内容，根据(26)计算输出们向量 $\boldsymbol{o_t}$，决定细胞状态的哪一部分可以输出，根据(27)计算最终隐藏状态 $\boldsymbol{h_t}$ 作为当前时间步的输出以及下一时间步的部分输入。

$$\boldsymbol{o_t} = \sigma(\boldsymbol{W_o} \cdot [\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_o}) \tag{26}$$

$$\boldsymbol{h_t} = \boldsymbol{o_t} \odot \mathbf{tanh}(\boldsymbol{C_t}) \tag{27}$$

本文的实验模型使用双向循环层，结果传入全连接层经 Sigmoid 函数激活后进行预测。损失函数使用二元交叉熵损失(6), 优化器使用 Adam。

3.9 1D CNN

一维卷积神经网络 (1D Convolutional Neural Network,1D CNN) 是一种基于卷积运算的神经网络，其核心思想是将文本视为一维序列数据，并使用卷积核 (Kernel) 在序列上滑动，提取局部特征。每个文档数据经过嵌入层的处理之后转换为嵌入向量的序列，传入卷积层，每个卷积层包含多个卷积核，分别提取不同的局部特征。每个卷积核都是一个小的权重矩阵，在嵌入向量的序列上滑动计算，它会与 n 个词向量 (n 是卷积核的大小, 默认为 3) 进行点积，产生新的特征值。每个卷积核在整个序列上滑动完之后，会生成一个一维的特征图。所有的特征图随后被传入池化层，池化层的目的是降维和突出最重要的特征，本文使用的是最大值池化 (MaxPooling), 在特征图上以固定大小的窗口滑动，并只保留窗口内的最大值。池化结果再次传入卷积层进行卷积，多次循环操作之后，数据被压缩成为更小更抽象的特征向量。将最后一层池化层的输出通过展平层转换为一个一维向量，输入全连接层，经 Sigmoid 激活后进行预测。损失函数使用二元交叉熵损失(6), 优化器使用 Adam。

3.10 BERT & RoBERTa

BERT(Bidirectional Encoder Representations from Transformers) 是一种预训练语言模型，其核心是 Transformer 架构中的 Encoder 部分，利用自注意力机制 (Self-Attention Mechanism) 来理解词语之间的关系，从而生成高质量的词嵌入。BERT 能够同时从左侧和右侧的上下文理解词语，并且在大规模语料库上进行了预训练，学习了丰富的语言知识，包括语法、语义和句法结构。我们无需从头训练，只需要在预训练的 BERT 模型上进行微调 (fine-tuning)。预训练的主要任务为掩码语言模型 (MLM) 和下一句预测 (NSP)。

在使用 BERT 解决情感分析任务时，我们只需进行简单的数据清洗，去除文档中的网页以及特殊字符，不需要做进一步的数据处理。文档输入首先传入嵌入层，分别进行:1) 词嵌入：为词语提供基本的语义信息；2) 段嵌入：为模型提供句子段落的信息;3) 位置嵌入：使用固定的正弦-余弦函数生成位置向量，提供词语在序列中的位置信息。三者相加，形成一个融合了所有基础信息的最终输入嵌入向量。该序列的嵌入向量表示为一个矩阵 $\boldsymbol{X}$, 其中每一行 $\boldsymbol{x_i}$ 是第 i 个词语的嵌入向量，传入 Transformer Encoder 层。模型使用三个可学习的权重矩阵，将输入矩阵 $\boldsymbol{X}$ 投影到三个不同的向量空间，分别得到查询矩阵 $\boldsymbol{Q}$, 键矩阵 $\boldsymbol{K}$，值矩阵 $\boldsymbol{V}$ 即(28)(29)(30)

$$\boldsymbol{Q} = \boldsymbol{X}\boldsymbol{W_Q} \tag{28}$$

$$\boldsymbol{K} = \boldsymbol{X}\boldsymbol{W_K} \tag{29}$$

$$\boldsymbol{V} = \boldsymbol{X}\boldsymbol{W_V} \tag{30}$$

我们通过计算查询矩阵与键矩阵的点积，来衡量每个词语与其他所有词语的关联程度，即(31), 其中 $\boldsymbol{Q}\boldsymbol{K^T}$ 是一个 $n \times n$ 的矩阵，其中每个元素 (i,j) 都是 $\boldsymbol{q_i}$ 与 $\boldsymbol{k_j}$ 的点积，表示第 i 个词对第 j 个词的关注度，结果除以键向量维度的平方根 $\sqrt{d_k}$ 防止梯度过大，最后使用 softmax 函数将注意力分数转换为 (0,1) 的注意力权重，且每行权重和为 1。最后用注意力权重矩阵 $\boldsymbol{A}$ 对值矩阵 $\boldsymbol{V}$ 进行加权求和，

即(32)$\boldsymbol{Z}$ 是自注意力机制的最终输出矩阵，融合了句子中所有词语的信息，并且对更相关的词语给予了更高的权重。再将该矩阵输入多层 Transformer Encoder，进一步提取更高级别、更抽象的上下文信息。多次重复后，输出一个最终的向量序列。

$$\boldsymbol{A} = softmax(\frac{\boldsymbol{QK^T}}{\sqrt{d_k}}) \tag{31}$$

$$\boldsymbol{Z} = \boldsymbol{AV} \tag{32}$$

在情感分析任务中，我们使用的是 BertForSequenceClassification 模型，这是一个专门为序列分类任务设计的 BERT 模型，除了词向量序列，该模型还会在每个序列的开头添加一个特殊标记 [CLS]，其对应的最终隐藏状态被特别训练，用于聚合整个输入序列的信息。最终向量序列中含有 [CLS] 标记的向量被传入分类头 (一个全连接层), 映射到二维，得到模型对积极与消极情感的预测分数，比较大小进行预测。

RoBERTa(Robustly optimized BERT pretraining approach) 在 BERT 的基础上，对预训练方法进行了优化。它在掩码语言模型任务中使用动态掩码，在每次向模型提供数据时，都动态生成新的掩码模式。这意味着一个句子在不同的训练周期中，被遮盖的词语是不同的。它移除了下一句预测任务。它采用了更大的训练数据和批处理大小，以及训练更长时间，取得比 BERT 更好的性能。

3.11 Large Language Model

大语言模型 (Large Language Model,LLM) 是具有强大的语言理解和推理能力的通用模型。我们通过设计一个清晰、明确的提示 (Prompt)，将情感分析任务转化为一个自然语言问答任务描述给模型，模型利用其在海量数据中学到的通用语言理解能力，直接对文本进行分析和分类。本文使用的是"qwen-plus" 模型。

4 Experiments

4.1 Bags of Words

使用 sklearn 库中的 CountVectorize 实现一个词、一个词 + 两个词、一个词 + 两个词 + 三个词的三种词袋。数据集中前 40K 的数据用作训练集，后 10K 数据用作测试集。仅通过训练集中的评论来构建词汇表，且同一词汇表将被应用于测试集。分别使用逻辑回归 (Logistic Regression)、线性支持向量机 (LSVM)、朴素贝叶斯 (NB) 进行机器学习。评测指标为准确率 (Accuracies)。

表 1: 基于词袋实验准确率结果

Methods	Unigrams	Uni+Bigrams	Uni+Bi+Trigrams
Logistic Regression	88%	90%	90%
LSVM	86%	90%	89%
NB	85%	88%	89%

4.2 TFIDF

实现一个词、一个词 + 两个词、一个词 + 两个词 + 三个词的三种 TF-IDF 词袋. 数据集中前 40K 的数据用作训练集，后 10K 数据用作测试集。分别使用逻辑回归 (Logistic Regression)、线性支持向量机 (LSVM)、朴素贝叶斯 (NB) 进行机器学习。评测指标为准确率 (Accuracies)。

表 2: 基于词频实验准确率结果

Methods	Unigrams	Uni+Bigrams	Uni+Bi+Trigrams
Logistic Regression	89%	89%	88%
LSVM	89%	90%	90%
NB	86%	89%	89%

4.3 深度学习方法 Deep Learning

使用 2.2.4进一步处理后的数据, 应用基于 Tensorflow 的多层感知机 (MLP)、循环神经网络 (RNN)、长短时神经网络 (LSTM)、1D 卷积神经网络 (1D CNN) 进行深度学习。随机抽取 80% 的数据作为训练集，剩余 20% 数据作为测试集。评测指标为准确率 (Accuracies)。

表 3: 深度学习实验准确率结果

Methods	Accuracies
MLP	87.0%
RNN	84.0%
LSTM	88.9%
1D CNN	89.7%

4.4 预训练模型以及大模型调用 Pre-trained Models & LLMs

使用基于 Hugging Face 库的 BertForSequenceClassification 和 RobertaForSequenceClassification 进行本地微调后训练，随机选取 70% 的数据作为训练集，15% 的数据作为验证集，15% 的数据作为测试集。评测指标为准确率 (Accuracies)。

调用”qwen-plus” 的 API，随机选取 20% 的数据作为测试集。

表 4: 预训练模型以及大模型调用实验准确率结果

Methods	Accuracies
BERT	91.9%
RoBERTa	92.7%
qwen-plus	94.5%

5 Summary

根据上述实验结果汇总得到表 5, 调用"qwen-plus" 大模型具有最高的准确率 94.5%, 使用预训练模型进行本地微调也可以达到 92% 左右的较高准确率。

表 5: 实验准确率结果汇总

Methods	Accuracies
Logistic Regression with BOW	90.0%
LSVM with BOW	90.0%
NB with BOW	89.0%
Logistic Regression with TFIDF	89.0%
LSVM with TFIDF	90.0%
NB with TFIDF	89.0%
MLP	87.0%
RNN	84.0%
LSTM	88.9%
1D CNN	89.7%
BERT	91.9%
RoBERTa	92.7%
qwen-plus	94.5%

6 More Information

6.1 References

1.https://dropsofai.com/sentiment-analysis-with-python-bag-of-words/

2.https://dropsofai.com/sentiment-analysis-with-python-tfidf-features/

3.https://dropsofai.com/sentiment-classification-with-deep-learning-rnn-lstm-and-cnn/

6.2 Github Link

https://github.com/GabrielMu2006/Sentiment-Analysis